UNIVERSITAT POLITÈCNICA DE CATALUNYA
BARCELONATECH
Escola Tècnica Superior d'Enginyeria
de Telecomunicació de Barcelona

telecos BCN

Detecció d'Atacs en Xarxes 5G mitjançant Machine Learning: Un Enfocament Basat en Datasets Públics.

Treball de Final de Grau
Presentat a l'Escola Tècnica Superior
d'Enginyeria de Telecomunicació de Barcelona
de la Universitat Politècnica de Catalunya
per

Elías Vallina Mora

En compliment parcial
dels requisits per a l'obtenció del

GRAU EN ENGINYERIA DE TECNOLOGIES I SERVEIS DE TELECOMUNICACIÓ

Directora: Umbert Juliana, Anna

Barcelona, Octubre de 2025

Resum

Aquest Treball de Fi de Grau se centra en l'aplicació de tècniques de Machine Learning per a la detecció d'intrusions en xarxes 5G, utilitzant conjunts de dades públics de referència com CIC-IDS2017, CIC-IDS2018 i UNSW-NB15. El projecte desenvolupa i avalua pipelines independents de processament i classificació per a cada conjunt de dades, incloent tècniques de selecció de variables i models avançats. L'ús de la mateixa lògica metodològica en escenaris diferents permet obtenir una visió comparativa del rendiment dels models en entorns diversos. Els resultats mostren la viabilitat d'aquest enfocament i posen en relleu les fortaleses i limitacions dels models emprats, aportant una anàlisi crítica sobre la seva aplicació en la seguretat de xarxes reals.

Resumen

Este Trabajo de Fin de Grado se centra en la aplicación de técnicas de *Machine Learning* para la detección de intrusiones en redes 5G, utilizando datasets públicos de referencia como CIC-IDS2017, CIC-IDS2018 y UNSW-NB15. El proyecto desarrolla y evalúa *pipelines* independientes de procesamiento y clasificación para cada dataset, incluyendo técnicas de selección de variables y modelos avanzados. La aplicación de la misma lógica metodológica en escenarios distintos permite obtener una visión comparativa del rendimiento de los modelos en diferentes contextos de tráfico. Los resultados demuestran la viabilidad del enfoque y destacan las fortalezas y limitaciones de los modelos empleados, ofreciendo un análisis crítico sobre su uso en escenarios reales de ciberseguridad en redes.

Summary

This Bachelor's Thesis focuses on applying *Machine Learning* techniques to intrusion detection in 5G networks, using public benchmark datasets such as CIC-IDS2017, CIC-IDS2018, and UNSW-NB15. The project develops and evaluates independent processing and classification pipelines for each dataset, including feature selection techniques and advanced models. Applying the same methodological logic in different scenarios provides a comparative view of the models' performance across diverse traffic contexts. The results demonstrate the feasibility of this approach and highlight both the strengths and limitations of the applied models, offering a critical analysis of their applicability in real-world network security environments.

A Jesucrist, per la seva guia i força durant tot aquest viatge.

Agraïments

Voldria expressar el meu més profund agraïment a la meva tutora per haver cregut en mi i en el meu projecte, així com per la seva guia, amabilitat i atenció al llarg d'aquesta tesi.

També dono les gràcies als professors de l'ETSETB, especialment a aquells que m'han donat suport en els moments de dificultat durant aquest camí.

A més, vull agrair als meus companys, que m'han ofert ajuda i han estat al meu costat sempre que ho he necessitat.

Finalment, estic sincerament agraït a la meva família —especialment als meus pares i germans — pel seu amor i encoratjament incondicionals, essencials al llarg dels meus estudis.

Historial de revisió i aprovació

Revisió	Data	Objectiu
1.0	10/03/2025	Creació del Document
1.1	30/06/2025	Revisió del document
2.0	05/10/2025	Modificacions post-revisió
3.0	19/10/2025	Versió final

LLISTA DE DISTRIBUCIÓ DEL DOCUMENT

Paper al TFG	Cognom/s i Nom
Estudiant	Vallina Mora, Elías
Tutor del projecte	Umbert Juliana, Anna

Escrit per:		Revisat i aprovat per:	
Data	19/10/2025	Data	20/10/2025
Nom	Vallina Mora, Elías	Nom	Umbert Juliana, Anna
Rol	Autor del Projecte	Rol	Tutora del Projecte

Índex

Resum 2
Dedicatòria 3
Agraïments 4
Historial de revisió i aprovació 5
Índex 6
Índex de figures 8
Índex de taules 9
Sigles i acrònims 10

1 Introducció 11
1.1. Justificació i context 12
1.2. Objectius del treball 13
1.3. Requisits i especificacions 14
1.4. Mètodes i procediments 15
1.5. Pla de treball 15
1.6. Desviacions respecte del pla inicial 17

2 Estat de l'art de la tecnologia utilitzada o aplicada en aquest TFG 18
2.1. Panorama general i motivació 18
2.2. Models utilitzats a la pràctica 18
2.3. Enginyeria de features a nivell de flux 19
2.4. Mètriques i punt d'operació (sense calibratge) 18
2.5. Bones pràctiques de reproduïbilitat i antifuita 20

3 Metodologia / desenvolupament del projecte 21
3.1. Visió general del pipeline 21
3.2 CIC-IDS2018: Ingesta i normalització 22
3.3.Perquè es produeixen fuites i com les evitem 23
3.4. Clau de flux i particionat sense fuites 24
3.5. Preprocessament i selecció de variables (deploy safe) 26
3.6. Model principal: Histogram-Based Gradient Boosting 27
3.7. Procediment d'entrenament i validació 29
3.8. Selecció del llindar τ (criteri de Neyman-Pearson) 29

4 Resultats 31
4.1. Experiments i proves 31
4.2. Resultats a VAL 31
4.3. Resultats a TEST (mateix τ) 32
4.4. Matriu de confusió a TEST (al llindar τ) 33
4.5. Corbes ROC i PR (VAL/TEST) 34
4.6. Cost computacional i recursos 35

4.7. Discussió 35
4.8. Resum del capítol 36

5 Anàlisi de sostenibilitat i implicacions ètiques 37
5.1. Visió general 37
5.2. Consideracions ètiques i de privacitat 37
5.3. Impacte econòmic (costos i beneficis) 38
5.4. Impacte social i legal 39
5.5. Sostenibilitat ambiental (energia i petjada de carboni) 39
5.6. Riscos i mitigacions 40
5.7. Bones pràctiques de desplegament i monitoratge 41
5.8. Limitacions 41
5.9. Resum del capítol 42

6 Conclusions i Línies Futures 43
6.1. Conclusions principals 43
6.2. Acompliment dels objectius 43
6.3. Limitacions 44
6.4. Línies futures 44
6.5. Cloenda 45

Bibliografia 46
Apèndix A. Altres definicions 48

Índex de figures

1.1. Diagrama de Gantt del projecte 16
3.1. Diagrama de l'estructura general del pipeline de CIC-IDS2018 21
3.2. Fragment de CIC de la captura del conjunt de Wednesday 22
4.1. Importància per permutació (VAL) 32
4.2. Matriu de confusió a TEST (τ^* de VAL) 33
4.3. Corbes ROC (VAL i TEST; punt τ^*) 34
4.4. Corbes PR (VAL i TEST; punt τ^*) 34

Índex de taules

3.1. Histogram-Based Gradient Boosting (HGB): paràmetres i entorn 30
4.1. Mètriques a VAL (al llindar τ^* triat per NP) 31
4.2. Mètriques a TEST (al mateix τ^* de VAL) 33
4.3. Cost computacional (CPU) i recursos 35
5.1. Riscos i mitigacions 40

Sigles i acrònims

API Application Programming Interface

AUPRC Area Under the Precision–Recall Curve

AUROC Area Under the ROC Curve

CIC-IDS2018 Canadian Institute for Cybersecurity — Intrusion Detection System 2018 dataset

CLI Command-Line Interface

CPU Central Processing Unit

CSV Comma-Separated Values

DL Deep Learning

ETSETB Escola Tècnica Superior d'Enginyeria de Telecomunicació de Barcelona

FN False Negative (fals negatiu)

FP False Positive (fals positiu)

FPR False Positive Rate (taxa de falsos positius)

GiB Gibibyte (2^{30} bytes)

GPU Graphics Processing Unit

HGB Histogram-Based Gradient Boosting

IAT Inter-Arrival Time (interval entre arribades)

IDS Intrusion Detection System (sistema de detecció d'intrusions)

JSON JavaScript Object Notation

KS Kolmogorov–Smirnov (test/estadístic per drift)

LGBM LightGBM (Gradient Boosting de Microsoft)

LR Logistic Regression (regressió logística)

ML Machine Learning (aprenentatge automàtic)

NOC Network Operations Center

NP Neyman–Pearson (criteri de selecció del llindar)

PR Precision–Recall (corba de precisió–record)

PSI Population Stability Index (indicador de drift)

QA Quality Assurance (control de qualitat)

RAM Random Access Memory

RGPD/GDPR Reglament General de Protecció de Dades / General Data Protection Regulation

ROC Receiver Operating Characteristic (corba ROC)

SGD Stochastic Gradient Descent

SOC Security Operations Center

TN True Negative (veritable negatiu)

TP True Positive (veritable positiu)

TPR True Positive Rate (sensibilitat/recall)

UNSW-NB15 UNSW Network Security 2015 dataset

URL Uniform Resource Locator

VAL/TEST/TRAIN Conjunts de validació / test / entrenament

XGBoost Extreme Gradient Boosting

ZIP Format comprimit d'arxius

CAPÍTOL 1

Introducció

1.1.1 Context

Les xarxes 5G han multiplicat la capacitat i reduït la latència, però també han ampliat el terreny on es poden produir atacs. Una intrusió és qualsevol accés, ús o alteració no autoritzats d'una xarxa o d'uns sistemes, amb finalitats com l'obtenció d'informació, la modificació o destrucció de dades, o la interrupció de serveis. Els actors poden ser delinqüència organitzada, grups amb objectius d'espionatge o sabotatge, personal intern que abusa del seu accés o bots i eines automatitzades que exploren la xarxa a la recerca de debilitats.

Els atacs acostumen a seguir una seqüència similar: identificació de punts febles, obtenció d'un punt d'entrada i consolidació de la presència, desplaçament per l'entorn digital i, finalment, execució de l'objectiu (accés a informació, alteració de dades, interrupció de serveis o ús indegut de recursos). Sovint s'empren tècniques d'evasió per dificultar-ne la detecció.

El context 5G complica la defensa per l'existència de més dispositius connectats, molt més trànsit i serveis distribuïts entre centres de dades i punts d'accés de proximitat, amb una segmentació dinàmica. A més, el xifrat generalitzat limita la inspecció detallada del contingut. Per això guanya rellevància analitzar com es comporta una connexió —durada, volum i ritme d'intercanvi de dades—, és a dir, l'estudi a nivell de flux.

La protecció efectiva és en capes: mesures preventives i d'higiene (actualitzacions, credencials robustes i verificació en dos passos, principi de mínim privilegi, segmentació), i capacitats de detecció i resposta que combinen registres, correlació i sistemes de detecció d'intrusions. En molts entorns operatius predominen els IDS de signatures per la seva rapidesa i el seu baix cost davant amenaces conegudes; com a complement, els enfocs basats en dades i *Machine Learning* ajuden a identificar comportaments anòmals i variants noves. Són moltes les organitzacions que comencen a desplegar IDS híbrids (signatures + ML), aprofitant els avantatges i mitigant les mancances de cada enfoc.

1.1.2. Justificació

Actualment, tot i que els sistemes de detecció d'intrusions basats en signatures són encara l'opció més utilitzada, en aquest treball proposem un enfocament complementari basat en Machine Learning, amb detecció a nivell de flux i control de falsos positius, per facilitar un desplegament auditable en entorns 5G reals.

Al llarg d'aquesta investigació s'ha disposat de diversos datasets d'accés públic per a l'entrenament dels models, generats per institucions reconegudes i punteres en ciberseguretat. Principalment, tres conjunts: CIC-IDS2018 i CIC-IDS2017 (del Canadian Institute for Cybersecurity), i UNSW-NB15 (de la University of New South Wales). Aquests conjunts contenen nombrosos fluxos (benignes o d'atac), cadascun amb característiques de nivell de transport i d'aplicació reportades en el mateix registre.

Metodològicament, apliquem un procés reproduïble: lectura i normalització de dades, i divisió en tres parts sense superposició —una per entrenar el model i aprendre transformacions, una segona per ajustar el llindar d'alarma i controlar el sobreajustament, i una tercera per avaluar la capacitat de predicció del model.

Pel que fa a les tècniques, durant el projecte s'han provat diversos models de ML, principalment tres: XGBoost, SGD-Logistic Regression i Histogram-Based Gradient Boosting (HGB). Aquesta tesi centra l'explicació en el darrer, HGB, per la seva bona relació rendiment/cost, ja que l'objectiu és mantenir un enfocament realista, coherent amb l'afluència de trànsit molt elevada pròpia dels entorns 5G. L'apliquem a CIC-IDS2018, atesa la riquesa de classes i la varietat i complexitat dels atacs que conté.

1.2 Objectius del treball

1.2.1 Objectiu general

Donada la necessitat en el món real en que els servidors reben infinitat de paquets cada segon, per lo que es pretén minimitzar els falsos positius (usuaris de la xarxa que fan ús normal dels quals no es volem marcar com a maliciosa la informació que transmeten i reben), l'objectiu principal d'aquest treball és:

- ➢ Dissenyar, implementar i avaluar un model eficient i reproduïble de IDS basat en ML, sobre CIC-IDS2018, amb una capacitat de detecció bona, fiable, i ràpida, i alhora obtenint un FPR, *taxa de falsos positius,* de com a màxim α=0.005%.

1.2.2 Objectius específics

- ➢ Evitar fuites amb clau de flux(§3.4) fent divisió per clau, controlant prevalences (proporció d'anomalies dins d'un dataset).
- ➢ Seleccionar característiques (features) mitjançant diverses tècniques robustes per a un bon desplegament del model HGB.
- ➢ Seleccionar al procés de validació del model, amb la tècnica de Neyman-Pearson(§3.7), un umbral τ que classificarà la predicció feta pel model, com anòmala o benigna.
- ➢ Reportar i estudiar les mètriques essencials universals d'evaluació d'un model de Machine Learning com són: AUROC, *Area Under the ROC Curve*, AUPRC, *Area Under the Precision–Recall Curve*, F1 i Recall@FPR=α, entre d'altres, així com quantificar el cost computacional (temps, RAM, mida de model, latència).
- ➢ Deixar una traça completa d'artefactes per a auditoria.

1.3 Requisits i especificacions

Dades. Tres datasets corresponents a tres dies de captura diferents (Wednesday, Thursday, Friday) en format CSV originals de CIC-IDS2018; conversió a format Parquet i inventaris per dia.

Reproduïbilitat. En aquest treball, "reproduïble" significa que, donats els mateixos artefactes (model entrenat, definició de *features* i llindar τ) i la mateixa entrada, el sistema retorna la mateixa puntuació i decisió a qualsevol màquina. Ho assegurem gràcies a les llavors:

Llavors i aleatorietat. Per garantir que dues execucions idèntiques produeixin exactament els mateixos resultats, es fixa una llavor global (per exemple, *seed* = 42; qualsevol nombre és igualment vàlid) i per a bloquejar les operacions i decisions d'aleatorietat interna de llibreries de python que s'utilitzen en el projecte (Numpy, Pandas, scikit-learn, entre d'altres). D'aquesta manera, el pipeline queda determinista i auditable: mateixa entrada + mateixos paràmetres $\Rightarrow$ mateix resultat $\Rightarrow$ consistència dels experiments.

Anti-fuita. Concepte desenvolupat i molt important en el present treball, que pretén evitar que hi hagi una seqüència d'entrenament ben formulada per a evitar uns resultats poc fiables de la qualitat del model. Per a més detall, llegir §3.3.

Mètriques, gràfiques i figures: per a obtenir els resultats del nostre model i poder evaluar la calitat i fiabilitat que ofereix.

Divisions i resultats: per a l'execució i implementació del model, es crearà un conjunt d'entrenament (TRAIN), un de validació (VAL) i un altre d'evaluació (TEST). Qualsevol dels tres conjunts tindrà elements dels tres dies de captura (Wednesday, Thursday, Friday), assignats seguint unes pautes i mètodes determinats.

Rendiment. Objectius mínims orientatius a assolir donat l'escenari actual (entorn 5G, necessitat de tècniques IDS ràpides i amb baix cost computacional): temps d'entrenament ≤15 min, pic de memòria RAM ≤ 3.0 GiB, mida del model final emprat≤ 10.0 MB, latència ≤ 1 ms/flux.

Artifactes. Al llarg del codi Python que es crea en aquest projecte, es lliuren arxius en format accessible de tipus JSON (rutes, versions, recull d'estadístiques, paràmetres, resultats, càlculs), scripts/notebooks versionats, README i ZIP.

Privacitat. Evitar identificadors crus (IPs/ports literals) com a features; prioritzar agregacions i senyals de comportament.

1.4 Mètodes i procediments

El llenguatge de programació utilitzat en aquest TFG és Python, i de fet és l'habitual en programes de Machine Learning. El detall metodològic del model és a §3.1. El codi, notebooks i scripts i artifactes estan versionats al repositori de GitHub del projecte. A nivell alt: ingestió i normalització, particionat per clau (anti-fuita), features deploy-safe (segures de desplegar), entrenament HGB i exportació d'artefactes per auditoria.

Enllaç GitHub del projecte: EliasVallina/CICIDS2018-repository

1.5 Pla de treball i diagrama de Gantt

En aquesta secció es presenta el diagrama de Gantt final del projecte. El pla cobreix des de la primera línia base fins a l'entrega de la memòria, passant per tot el pipeline sobre CICIDS2018 i la redacció. El cronograma reflecteix les etapes reals del treball:

- **Kick-off i abast:** Delimitació del problema, lectura inicial i fixació de criteris de reproductibilitat (llavors, artefactes, mètriques).
- **Línies base (benchmarks inicials):**
  - **Baseline 1:** CIC-IDS2017 com a presa de contacte amb l'stack.
  - **Baseline 2:** UNSW_NB15 per contrastar robustesa i fixar expectatives de mètriques/cost.
- **Ingesta i auditoria de dades (CICIDS2018):** Normalització dels fitxers, control de duplicats i traçabilitat.
- **Particionat sense fuites :** Construcció de la clau de flux i separació TRAIN/VAL/TEST per clau, amb control de prevalences.

- **Neteja numèrica i escalat train-only:** Imputació i escalat apresa només a TRAIN i aplicats idènticament a VAL/TEST.
- **Selecció de característiques:** Filtres (variància/correlació) i rànquing amb Ridge/Lasso per fixar un conjunt estable.
- **Entrenament del model HGB:** Llavors fixades i early stopping documentat; export del `model.pkl`.
- **Llindar τ (criteri NP):** Selecció de τ a VAL amb guarda de FPR.
- **Avaluació final:** Mètriques a VAL/TEST amb el mateix τ; generació de ROC/PR i matriu de confusió.
- **Cost computacional (CPU):** Mesura i informe del temps/recursos sota l'entorn definit.
- **Redacció de la memòria:** Metodologia (Cap. 1–3), resultats (Cap. 4) i apartats finals (Cap. 5–6).
- **Revisions i tancament:** Referències creuades, annexos, verificació d'artefactes (freeze) i entrega.

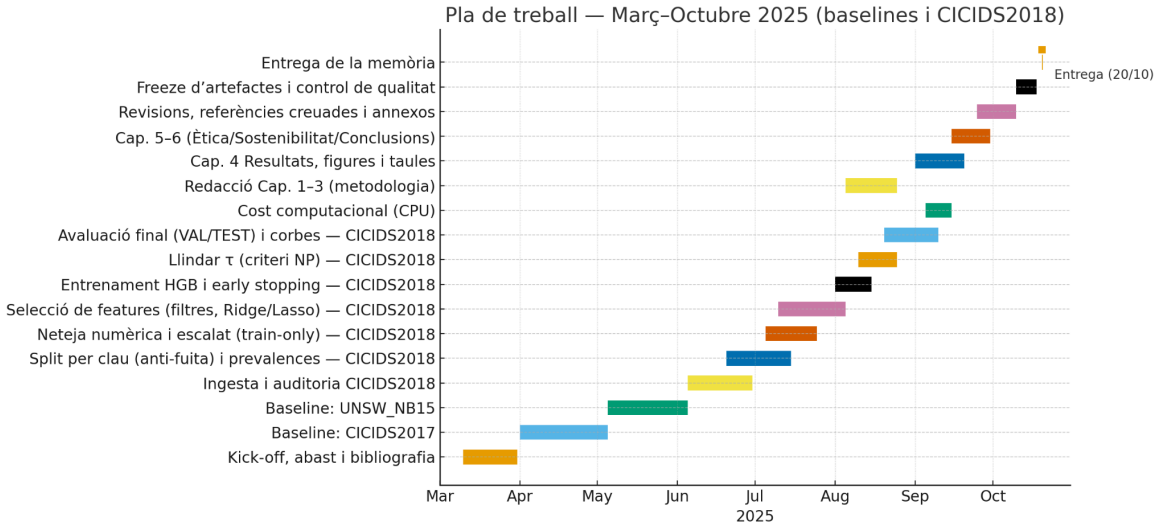

Figura 1.1 : Diagrama de Gantt del projecte

1.6 Desviacions respecte del pla inicial

El pla inicial contemplava un sistema híbrid (regles/"signatures" + algoritmes de *machine learning*). Tanmateix, la complexitat d'integració i manteniment de la capa de regles, el temps necessari per a la seva validació i la prioritat de garantir reproduïbilitat i traçabilitat van fer recomanable centrar el TFG exclusivament en ML.

CAPÍTOL 2

Estat de l'art de la tecnologia utilitzada o aplicada en aquest TFG

2.1 Panorama general i motivació

La detecció d'intrusions ha evolucionat des de motors basats en signatures (comparació de patrons coneguts) cap a enfocaments en aprenentatge automàtic (ML) i, en menor mesura, cap a aprenentatge profund (DL, *Deep Learning*).

Els sistemes per signatures ofereixen alta precisió en atacs coneguts, però pateixen una cobertura limitada davant variants noves; la seva eficàcia depèn del ritme d'actualització de signatures i del coneixement previ. [1]

En canvi, en els enfocament basats en aprenentatge automàtic es modelen patrons de comportament a partir de característiques de flux i poden detectar desviacions que no coincideixen exactament amb cap signatura. [2]

En entorns operatius, aquesta transició cap a ML demana resultats fiables i repetibles i, sobretot, mantenir les falses alarmes sota control.

2.2 Models utilitzats a la pràctica

Després d'una recerca dels models més utilitzats actualment, s'ha trobat que:

Els models lineals (Logistic Regression, amb o sense SGD, *Stochastic Gradient Descent*) són ràpids, transparents i adequats com a baseline; sovint serveixen per estimar fins on arriba la separabilitat lineal de les *features*. [8]

Ensamblatges d'arbres esdevenen l'elecció habitual quan cal capacitat no lineal i eficiència en la CPU donat un escenari similar a l'entorn 5G actual:

- **Random Forest**: robust però menys pràctic quan cal fixar amb precisió un punt d'operació (p. ex., FPR $\leq \alpha$).

- **Gradient Boosting** (XGBoost/LightGBM/HGB): equilibri molt bo entre rendiment predictiu i control del cost. [9] Les variants basades en histogrames redueixen memòria i acceleren l'entrenament mantenint competitivitat.
- **Deep Learning**: CNN/LSTM sobre fluxos o seqüències de paquets poden capturar dependències temporals, però sovint requereixen més dades, GPU i tenen una traçabilitat i cost superiors, no sempre justificats en entorns amb restriccions operatives. [10]

2.3 Enginyeria de features a nivell de flux

La literatura coincideix en privilegiar senyals de comportament respecte d'identificadors crus (IPs, ports) que poden induir memorització i pitjor generalització . Són habituals:

- Taxes de paquets/bytes.
- Intervals entre arribades (IAT, *Inter-Arrival Time*) i mesures de variabilitat temporal.
- Comptadors direccionalitzats (*forward/backward*).
- Flags i agregats (p. ex., PSH/ACK).
- Durades de flux.

Aquests descriptors, combinats amb processos de normalització o min-max apresos només en train, es mostren estables per a desplegament .

2.4 Mètriques i punt d'operació (sense calibratge)

Considerem la matriu de confusió al llindar τ: TP (veritables positius), FP (falsos positius), TN (veritables negatius) i FN (falsos negatius).

En aquest treball fem servir quatre mètriques al punt operatiu:

$$\text{precision} = \frac{TP}{TP + FP}\,; \quad \text{recall (TPR)} = \frac{TP}{TP + FN}$$
$$\text{FPR} = \frac{FP}{FP + TN}\,; \qquad F_1 = 2 \cdot \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}$$

Mentre que Precision indica la fracció d'alertes que realment són atacs —mesura com de "netes" són les alarmes, Recall (TPR) és la fracció d'atacs reals que detectem —la cobertura del sistema. False Positive Rate (FPR) és la fracció de trànsit benigne que marquem per error com a atac —el cost d'alarmes falses, i finalment F1-score és la mitjana harmònica de *precision* i *recall*, i equilibra puresa d'alarma i cobertura.

Recall@FPR=α :

$$\tau^* = \min\{\tau \mid \mathrm{FPR}_{\mathrm{VAL}}(\tau) \leq \alpha\}, \qquad \mathrm{Recall@FPR} = \alpha := \mathrm{TPR}_{\mathrm{VAL}}(\tau^*)$$

On τ^*és el llindar escollit entre tots els llindars τ possibles.

Mètriques de *ranking*.

- AUROC (*Area Under the ROC Curve*): àrea sota la corba TPR vs. FPR en variar τ; mesura la capacitat d'ordenar positius per davant de negatius.
- AUPRC (*Area Under the Precision–Recall Curve*): àrea sota Precision vs. Recall; en prevalences baixes és sovint més informativa que AUROC.

Notes d'aquest TFG.

- No s'aplica calibratge de probabilitats: s'opera directament amb les puntuacions de HGB.
- En els resultats (§4) es reporten AUROC i AUPRC (qualitat de *ranking*) i, al punt operatiu definit a §3.7, Precision, Recall, F1 i Recall@FPR=α.

2.5 Bones pràctiques de reproduibilitat i antifuita

Una part rellevant de la literatura recent subratlla que resultats massa optimistes sovint provenen de fuites: el mateix host/flux apareix a train i test, o es prenen decisions de preprocessament aprenent informació de val/test. [13] Les bones pràctiques demanen:

1. Particionat per clau (flux o host) abans de qualsevol aprenentatge,
2. Aprendre escales/transformacions únicament a l'entrenament.
3. Fixar llavors i registrar versions utilitzades.
4. Exportar artefactes i manifestos per poder auditar i replicar. [15]

CAPÍTOL 3

Metodologia / desenvolupament del projecte

3.1 Visió general del pipeline

L'objectiu és transformar els CSV originals de CIC-IDS2018 en un sistema d'inferència reproduïble: llegim i normalitzem dades, definim i apliquem una clau de flux per construir els conjunts train/val/test sense fuites, preparem un conjunt de característiques (features) deploy-safe, i entrenem HGB (Histogram-Based Gradient Boosting). Tota la traça (versions, paràmetres, mètriques) queda enregistrada en manifestos i artefactes exportables.

L'escalat i qualsevol transformació es tenen en compte només amb TRAIN i s'apliquen a VAL/TEST sense re-ajustos, mantenint la traçabilitat d'artefactes.

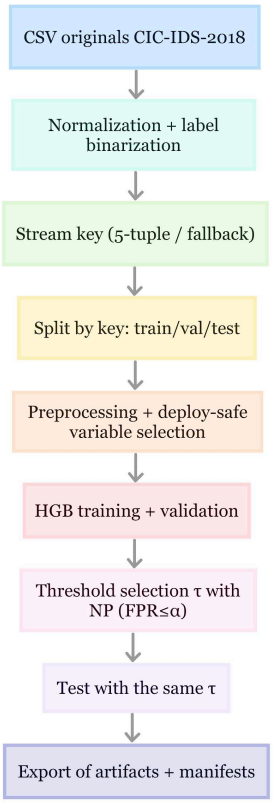

Figura 3.1: Diagrama de l'estructura general del pipeline de CIC-IDS2018. .

3.2 CIC-IDS2018: Ingesta i normalització

El dataset CIC-IDS2018 està organitzat per tres arxius en format CSV, corresponent cada un a un dia diferent (Wednesday,Thursday,Friday) en que es van fer l'experiment al laboratori per Canadian Institute for Cibersecurity, amb escenaris i famílies d'atac diferents (p. ex., escaneig de ports, DoS/DDoS, intents de *brute force* d'autenticació, trànsit de botnet i atacs web)., i cada dia presenta 1 048 575 fluxos, de 80 features cadascun.

Nota: cada fila del dataset conté un flux i els valors de les 80 features, mentre que cada columna conté tots els valors d'un feature (exemple de features: `label, srcip, proto, srcip, fwd_iat_mean`).

A continuació es mostra una captura de l'entorn de treball, on s'imprimeixen 10 primers fluxos del csv de Wednesday:

Wednesday-14-02-2018_TrafficForML_CICFlowMeter.csv — primeras 10 filas

	Dst Port	Protocol	Timestamp	Flow Duration	Tot Fwd Pkts	Tot Bwd Pkts	TotLen Fwd Pkts	TotLen Bwd Pkts	Fwd Pkt Len Max	Fwd Pkt Len Min	Fwd Pkt Len Mean	Fwd Pkt Len Std	Bwd Pkt Len Max	Bwd Pkt Len Min	Bwd Pkt Len Mean	Bwd Pkt Len Std	Flow Byts/s	Flow Pkts/s	Flow IAT Mean	Flow IAT Std	Flow IAT Max	Flow IAT Min	Fwd IAT Tot	Fwd IAT Mean	Fwd IA
0	0	0	14/02/2018 08:31:01	112641719	3	0	0	0	0	0	0.000000	0.000000	0	0	0.000000	0.000000	0.000000	0.026633	5.632086e+07	139.300036	56320958	56320761	112641719	5.632086e+07	139.3
1	0	0	14/02/2018 08:33:50	112641466	3	0	0	0	0	0	0.000000	0.000000	0	0	0.000000	0.000000	0.000000	0.026633	5.632073e+07	114.551299	56320814	56320652	112641466	5.632073e+07	114.5
2	0	0	14/02/2018 08:36:39	112638623	3	0	0	0	0	0	0.000000	0.000000	0	0	0.000000	0.000000	0.000000	0.026634	5.631931e+07	301.934596	56319525	56319098	112638623	5.631931e+07	301.9
3	22	6	14/02/2018 08:40:13	6453966	15	10	1239	2273	744	0	82.600000	196.741237	976	0	227.300000	371.677892	544.161528	3.873587	2.689152e+05	247443.778966	673900	22	6453966	4.609976e+05	123109.4
4	22	6	14/02/2018 08:40:23	8804066	14	11	1143	2209	744	0	81.642857	203.745545	976	0	200.818182	362.249864	380.733175	2.839597	3.668361e+05	511356.609733	1928102	21	8804066	6.772358e+05	532416.9
5	22	6	14/02/2018 08:40:31	6989341	16	12	1239	2273	744	0	77.437500	190.831154	976	0	189.416667	347.642569	502.479418	4.006100	2.588645e+05	291724.147911	951098	20	6989341	4.659561e+05	244363.8
6	0	0	14/02/2018 08:39:28	112640480	3	0	0	0	0	0	0.000000	0.000000	0	0	0.000000	0.000000	0.000000	0.026633	5.632024e+07	203.646753	56320384	56320096	112640480	5.632024e+07	203.6
7	0	0	14/02/2018 08:42:17	112641244	3	0	0	0	0	0	0.000000	0.000000	0	0	0.000000	0.000000	0.000000	0.026633	5.632062e+07	62.225397	56320666	56320578	112641244	5.632062e+07	62.2
8	80	6	14/02/2018 08:47:14	476513	5	3	211	463	211	0	42.200000	94.362069	463	0	154.333333	267.313175	1414.441998	16.788629	6.807329e+04	115865.792656	237711	24	476513	1.191282e+05	137379.9

Figura 3.2: Fragment de l'arxiu CSV original proporcionat per Canadian Institute for Cybersecurity corresponent al dia de Wednesday.

La ingesta es fa per fragments (*chunks*) (250.000 fluxos) per contenir memòria; es normalitzen capçaleres, es binaritza l'etiqueta (Benign/Normal/Background→0; resta d'atacs→1) i es persisteix al format Parquet, que redueix costos de lectura i facilitar la inspecció d'inventaris (files/dia, prevalences, camps absents). En aquesta fase s'eliminen columnes manifestament irrellevants (identificadors textuals llargs, timestamps crus) i s'anoten incidències (camps absents, valors impossibles) al manifest.

Resultat esperat: directori `prepared/` amb parts Parquet i `prepared_manifest.json` (compte de files, columnes detectades, mapeig d'etiquetes).

3.3 Per què es produeixen fuites i com les evitem

3.3.1 Què és una "fuita"?

Anomenem *fuita d'informació* qualsevol situació en què, durant la validació o el test, el model es beneficia d'haver vist abans el mateix cas (o un de massa semblant) a entrenament. Les mètriques resulten optimistes i no reflecteixen la capacitat real de generalitzar.

3.3.2 Per què passen?

En el nostre context, molts registres comparteixen la mateixa clau de flux (5-tupla o `flow_key`) i, a més, presenten molta correlació en la resta de columnes: durada, nombre de paquets, bytes, intervals (IAT), etc.
Si es fes la divisió per files aleatòries, és fàcil que fragments del mateix flux (o fluxos gairebé idèntics) caiguin repartits entre TRAIN i VAL/TEST. En aquest escenari, el model pot "reconèixer" patrons gairebé calcats als que ja ha memorizat a entrenament: no està resolent el problema per generalització, sinó per memòria.

3.3.3 Avaluar per memòria vs. avaluar per generalització

- *Per memòria*: el model aprofita que a VAL/TEST hi ha registres molt semblants (mateixa clau o clau afí) als que va veure a TRAIN. Resultat: mètriques inflades (AUROC, AUPRC, F1, etc.), poc fiables fora del dataset.

- *Per generalització*: el model s'enfronta a claus que no ha vist i a variacions reals dels patrons. Resultat: mètriques més honestes i robustes, útils per decidir un punt d'operació i anticipar-se a canvis d'entorn.

3.3.4 Política utilitzada per a evitar-ho

1. **Particionat per clau**: tots els registres amb la mateixa clau s'assignen junts a un únic conjunt (TRAIN/VAL/TEST). Això elimina la fuita per "trencament" de fluxos.

2. **Assignació determinista**: fem servir *hash* de `clau || SALT` i franges 70/15/15 sobre claus úniques (no sobre files). Amb la mateixa SALT, el *split* és reproduïble i auditable.

3. **Selecció del llindar (τ) només a VAL**: fixem el punt d'operació a VAL i el reutilitzem a TEST (sense re-ajustos), evitant *peeking* (§A2) sobre TEST.

3.3.5 Conclusió

La clau és no barrejar casos correlacionats entre conjunts. La divisió per clau força el model a demostrar generalització, que és exactament el que ens interessa: mètriques fiables, robustes i transferibles a l'operació real.

3.4 Clau de flux i particionat sense fuites

3.4.1 Definició de "clau de flux"

S'intenta construir la clau amb la 5-tuple clàssica:

`flow_key=srcip | sport | dstip | dsport | proto`

Casos amb camps incomplets

1. Reconstrucció des de `flow_id` (si és present) per recuperar IP/ports/protocol quan sigui possible.
2. Fallback determinista quan encara falten camps: es concatena una signatura estable de comportament i temporalitat del flux, p. ex.:

`flow_key=flow_id | duration | fwd_pkts | bwd_pkts | fwd_bytes | bwd_bytes`

Regla d'or: la mateixa clau ⟹ sempre el mateix conjunt.

Exemple:

- ➢ Flux amb `srcip=10.0.0.5`, *sport* desconegut, `dstip=10.0.0.12`, `dsport=443`, `proto=TCP`, `flow_id` disponible.
- ➢ Clau final: `10.0.0.5|flowid:7f3a9c12|10.0.0.12|443|TCP` (si no hi ha *sport* fiable).
- ➢ Si manca `flow_id`, s'empra el fallback amb durada i comptadors.

3.4.2 Objectiu i procés d'assignació

Garantir que cap flux (ni cap fragment que en provingui) aparegui en més d'un conjunt (TRAIN/VAL/TEST). Això elimina fuites d'informació i assegura que les mètriques de validació i test no quedin inflades per memòria del model. En particular, si un mateix flux es reparteix entre conjunts, el model pot memoritzar patrons d'aquell cas i les mètriques de validació/test queden artificialment altes; el particionat per clau ho evita.

Entenem per particionat per clau sense fuites com a fer el la divisió en els splits de TRAIN/VAL/TEST per clau de flux amb proporcions 70/15/15 sobre *claus úniques*, no pas sobre files (més d'una fila pot tenir la mateixa clau).

Què són les *claus úniques*? El conjunt de totes les claus diferents observades al dataset (la unió de claus dels tres dies), sense repeticions.

Com s'assignen a un *split*? Per a cada clau, calculem un valor "pseudoaleatori determinista" aplicant un hash a `clau || SALT` (SALT fix). Si el valor cau al primer tram (<0.70), la clau va a TRAIN; si cau al següent (0.70–0.85), va a VAL; i si cau a l'últim (≥0.85), va a TEST.

Així tots els fluxos que comparteixen una mateixa clau s'assignen junts al mateix conjunt i cap clau apareix en més d'un *split*, eliminant fuites. Com que les proporcions es defineixen sobre claus, el percentatge final de files pot diferir lleugerament de 70/15/15 segons quants fluxos aporta cada clau. Observi's que es dona més pes a TRAIN (70%) perquè és el conjunt que necessita més dades per entrenar bé el model.

Exemple: si la clau `K123` cau al tram <0.70, tots els seus fluxos van a TRAIN; cap flux amb `K123` podrà aparèixer a VAL o TEST.

3.4.3 Procediment operatiu seguit

1. Construcció de la clau per a cada registre (5-tuple ⟶ `flow_id` ⟶ *fallback*).
2. Càlcul de `h` amb SALT i assignació a TRAIN/VAL/TEST per bucket.
3. Verificacions:
    - Unicitat: cap clau apareix en més d'un conjunt.
    - Cobertura: totes les files tenen clau vàlida i conjunt assignat.
    - **Prevalences i correcta distribució de claus entre divisions**: Es requereix que la prevalença no varii gaire entre els tres conjunts i que alhora s'hagi aconseguit una distribució de claus amb un petit d'error permès respecte el 70%/15%/15% establert; En cas contrari, es canvia SALT i es repeteix el procés.
4. Persistència de la taula *clau⟶conjunt*, creada (`keys_split_map.parquet`).
5. Particionat físic de les taules Parquet a `prepared/splits/{train,val,test}`.
6. Gelat del particionat: una vegada validat, no es torna a generar per a aquest projecte; queda fixat al README i als manifests.

Observació (inventari de claus). *En l'anàlisi del conjunt utilitzat (Wednesday/Thursday/Friday de CIC-IDS2018) s'ha detectat detectat una distribució clarament long-tail de claus de flux, amb algunes "classes elefant" (claus que concentren milers de fluxos). En total, s'han identificat 34 956 claus úniques. Aquest patró reforça la decisió de particionar per clau, per evitar que un split estigui governat per vàries d'aquestes "classes elefant" i com a conseqüència el nostre model aprengui esbiaixat cap a aquelles poques identitats que, com bé se sap, comparteixen una correlació molt alta.*

3.5 Preprocessament i selecció de variables (deploy-safe)

L'estratègia de *features* és conservadora: es prioritzen senyals de comportament i s'exclouen identificadors amb risc de memorització (IPs, ports crus, identificadors textuals). El mòdul de selecció (basat en `seleccionvariablesids2018.py`) filtra columnes estables entre parts i reté el TOP-25 de variables deploy-safe (p. ex., taxes de paquets/bytes, IATs, comptadors fwd/bwd, flags agregats, durades). L'escalat (p. ex., *min–max*) i la imputació s'ajusten només amb TRAIN i s'apliquen a VAL/TEST sense re-ajustos. Es registren estadístics (mins/maxs), ordre de columnes i llistes d'atributs perquè qualsevol re-execució a partir de Parquet generi exactament els mateixos tensors (dtype float32).
Resultat esperat: `features_meta.json, scaler_minmax.json`, i matrius X_train/val/test amb 25 *features* finals.

Nota per a millor comprensió: Valors com protocol o port són codis i no magnituds amb distància geomètrica: 22 (SSH) ≠ 23 (Telnet) ≠ 8080 (HTTP-alt). Tractar-los com reals i normalitzar-los introdueix soroll (p. ex., "23 està més a prop de 22" no té cap sentit semàntic) i afavoreix memorització de patrons locals. Per això s'exclouen com a features crues i es prioritzen descriptors de comportament (taxes, IATs, comptadors, flags). Alternatives segures serien bucketitzar ports o codificar one-hot proto a nivell gros, però aquest TFG opta per no incorporar aquests codis directament per mantenir estabilitat i privacitat.

3.5.1 Selecció de variables

L'objectiu es reduir el conjunt de *features* a un TOP-25 "deploy-safe" evitant redundàncies i identificadors.

Procediment

1. **Filtres previs.** Eliminació de baixa variància i de parelles molt correlacionades ($|r| \geq 0{,}90$); dins de cada parella es conserva la variable amb més correlació amb l'etiqueta.

2. **Rànquing lineal.** S'estimen RidgeCV (magnitud de coeficients) i LassoCV (esparsitat) per prioritzar candidates.

3. **Selecció d'estabilitat.** *Stability selection* amb submostres estratificades; es retenen les *features* amb freqüència ≥ 0,60.

4. **Consens i mida.** A partir d'aquests passos es construeix un TOP preliminar (K=25) i, per al pipeline final, s'utilitza la llista de 25 *features*.

3.6 Model principal : Histogram-Based Gradient Boosting (HGB)

3.6.1 Principi de funcionament

HGB és *gradient boosting* amb arbres en què el model es construeix com una suma additiva d'arbres petits. A cada iteració *t* s'afegeix un arbre que corregeix l'error del model actual:

$$f_{t+1}(x) = f_t(x) + \sigma T_t(x)$$

amb σ (learning rate) com a pas d'actualització. En classificació binària s'optimitza la pèrdua logística (*log-loss*) sobre la puntuació *f(x)* (log-odds) i la probabilitat es calcula com:

$$p(x) = \sigma(f(x)) = \frac{1}{1 + e^{-f(x)}}$$

Operativament, cada arbre s'indueix per aprofitar la informació de gradient (i, si escau, de curvatura) i disminuir la pèrdua global quan s'afegeix al model.

3.6.2 Motor "histogram-based"

Abans de cercar particions, cada *feature* contínua es discretitza en bins (quantils). Això permet:

- agregar gradients/curvatures per bin en lloc de per valor,
- avaluar guanys de *split* amb prefixos acumulats de manera molt eficient,
- reduir cost de CPU i memòria mantenint rendiment competitiu.

Aquesta discretització és la clau perquè l'entrenament sigui ràpid i estable en CPU.

3.6.3 Controls de capacitat i regularització

El model limita el sobreajust combinant:

- `learning_rate = 0.10` — actualitzacions moderades; millora progressiva sense salts bruscos.
- `max_iter = 300` — sostre d'arbres; el nombre efectiu el determina l'aturada primerenca.

- `early_stopping = True, validation_fraction = 0.12, n_iter_no_change = 30` — es reserva un 12% de TRAIN per validar cada iteració i s'atura si no hi ha millora durant 30 iteracions.
- `min_samples_leaf = 250` — suport mínim per fulla; evita particions massa fines i aporta estabilitat, especialment amb classes minoritàries.
- `l2_regularization = 0.0` — penalització de fulles desactivada; es manté a zero en absència d'oscil·lacions.

3.6.4 Tractament del desbalanceig

En binari fem servir 0 = benigne i 1 = atac. Per compensar la classe minoritària a TRAIN apliquem pesos inversos a la prevalença (equivalent a `class_weight="balanced"` de scikit-learn):

$$w_{\text{pos}} = \frac{N}{2\,N_{\text{pos}}}; \quad w_{\text{neg}} = \frac{N}{2\,N_{\text{neg}}}$$

i, per tant:

`class_weight = {0: w_neg, 1: w_pos}.`

Els pesos es calculen només amb TRAIN i es mantenen fixos a VAL/TEST. Això incrementa el cost dels errors sobre la classe d'atac i ajuda a sostenir el recall al punt operatiu triat amb NP (FPR ≤ α), sense relaxar el sostre de falsos positius.

3.6.5 Sortides i ús operatiu

El model retorna puntuació $f(x)$ i probabilitat $\hat{p}$ (x). S'opera amb un llindar τ fixat a VAL amb criteri de Neyman–Pearson i reutilitzat a TEST. El paper d'HGB és proporcionar una puntuació estable sobre la qual aplicar τ.

3.6.6 Motivació específica en aquest treball

- Eficiència en CPU i memòria gràcies al motor per bins ⟶ entrenaments i deteccions ràpides i reproduïbles sense GPU.
- Capacitat no lineal amb un conjunt compacte de 25 *features* deploy-safe ⟶ captació d'interaccions rellevants en trànsit de xarxa sense complicar el desplegament.

- Control del biaix–variància amb `min_samples_leaf` i *early stopping* ⟶ reducció de sobreajust de manera simple i transparent.
- Determinisme i traçabilitat (`random_state=42`, criteris d'aturada documentats) ⟶ facilita auditoria i reentrenament controlat.
- Integració amb operació per llindar (NP) ⟶ facilita imposar FPR ≤ α a VAL i traslladar el mateix τ a TEST.

3.7 Procediment d'entrenament i validació

A partir de §3.4 disposem dels conjunts TRAIN i VAL amb distribucions de fluxos correctes segons els diversos criteris que s'han exposat en aquest capítol, aiixí com amb el mateix TOP-25 de features deploy-safe, imputació i min–max après només a TRAIN (aplicat a VAL/TEST sense reajustos). L'entrenament usa HistGradientBoostingClassifier [13] (híperparàmetres de §3.5) amb pesos de classe inversos a la prevalença i early stopping; el procés és determinista (llavor global i random_state).

Es calculen les puntuacions $s(x)$ sobre VAL i, amb elles, les mètriques i figures que es presenten a §4.

3.8 Selecció del llindar τ (criteri de Neyman–Pearson)

3.8.1 Definició i artefactes del llindar τ (criteri NP)

En un entorn d'IDS, el cost d'un excés d'alarmes (falsos positius) és crític. Per això s'aplica Neyman–Pearson (NP) a VAL: es tria el menor llindar τ tal que la taxa de falsos positius no superi un límit α prefixat:

$$FPR(\tau) = \frac{FP(\tau)}{FP(\tau) + TN(\tau)} \qquad \tau = min\{\tau \,|\, \overline{FPR}_{val}(\tau) \leq \alpha\}$$

Amb τ fixat, s'aplica sense canvis al TEST per obtenir Recall@FPR=α, F1, AUROC i AUPRC sobre el conjunt cec.

Resultat esperat: `decision_thresholds.json` amb τ i `metrics_val.json` (incloent FPR@τ, TPR@τ, F1@τ).

3.8.2 Paràmetres operatius (ENV) del contracte NP

A la pràctica, el criteri s'implementa amb els següents paràmetres d'entorn, que fixen el comportament operatiu i deixen traça per a auditoria:

- `IDS_MAX_FPR = 0.005` (α = 0.5%): límit màxim de FPR a VAL per seleccionar τ.
- `IDS_MIN_TPR = 0.60`: record mínim desitjat a VAL; si cap llindar compleix FPR≤α i TPR≥0.60, s'activa el *fallback*.
- `IDS_NP_MARGIN = 0.80`: marge operatiu conservador per traslladar τ a entorns amb possible *drift* (conté FP apujant lleument el llindar si cal).

Nota: Entenem per "drift" canvis en la distribució de dades entre períodes. Per més detall, vegeu la definició a §A1.

Fallback si no hi ha cap τ viable (NP): si la restricció FPR≤α i TPR≥IDS_MIN_TPR no té cap candidat, es tria el llindar amb F1 màxim sobre VAL i es deixa constància al manifest.

Seguidament es mostren els paràmetres més rellevants que formen part del model HGB, per a que el lector es pugui situar:

Paràmetre	**Valor**
Llibreria	scikit-learn (HistGradientBoostingClassifier)
Llavor global	42
`learning_rate`	0.10
`max_iter` (iteracions màx.)	300
Early stopping (pacience)	30 *(amb* `validation_fraction = 0.12`*)*
`max_depth`	None *(sense límit)*
`max_bins`	255
`l2_regularization`	0.0
Pesos de classe	manual (inversos a la prevalença)
Conjunt per a validació	VAL (fixe)
Escalat de features	Min-Max après a TRAIN
Features finals	25
Fraccions split (keys)	70%/15%/15% (per clau de flux; buckets 0-69 / 70-84 / 85-99)
α (límit de FPR a VAL)	0.5%

Taula 3.1 : *Histogram-Based Gradient Boosting =*

CAPÍTOL 4

Resultats

4.1 Experiments i proves

Els experiments exposats en el present treball es duen a terme sobre CIC-IDS2018 (Particionat per clau sense fuites (§3.3)). La llavor global és 42 i l'entorn d'execució és Linux x86_64 (kernel 6.6.105+), sessió CPU amb 12.7 GB de RAM i Python 3.12.12. Tots els temps i costos reportats s'han mesurat en aquest entorn (vegeu Taula 4.3). Els conjunts resultants tenen train/val/test = 60.11% / 17.20% / 22.69% i una prevalença d'anomalies de 27.21% / 34.66% / 46.69%, respectivament. El conjunt de *features* final conté 25 variables *deploy-safe* i l'HGB s'entrena amb els hiperparàmetres de la Taula 3.1. El llindar operatiu τ s'ha triat a VAL amb Neyman–Pearson (NP) exigint FPR $\leq \alpha$ (α = 0.5%).

4.2 Resultats a VAL

4.2.1 Selecció de τ

Triem el llindar τ a VAL amb Neyman–Pearson, exigint FPR $\leq \alpha$ (α = 0,5%) i aplicant-lo sense reajust a TEST. El τ escollit compleix el límit de FPR amb marge i reflecteix una política operativa que prioritza pocs falsos positius: mantenim una precisió molt alta a canvi d'un recall moderat, coherent amb l'ús en SOC/NOC. Les mètriques de rank (AUROC/AUPRC) indiquen bona capacitat d'ordenació independent del llindar; els valors exactes consten a la Taula d'aquesta secció.

Conjunt	τ^*	FPR ($\leq \alpha$)	TPR (Recall)	Precision	F1	AUROC	AUPRC
VAL	0.000045	0.003388 (α = 0.005)	0.500	0.987	0.664	0.86340	0.81793

Taula 4.1 : Mètriques a VAL (al llindar τ^* triat per NP); τ^* és el llindar operatiu triat amb NP a VAL; α és el límit adoptat per a l'operació.

4.2.2 Importància de variables (RESULTATS, VAL)

A continuació es presenta el rànquing del Top-15 de *features* més influents segons importància per permutació a VAL, juntament amb el gràfic del rànquing complet.

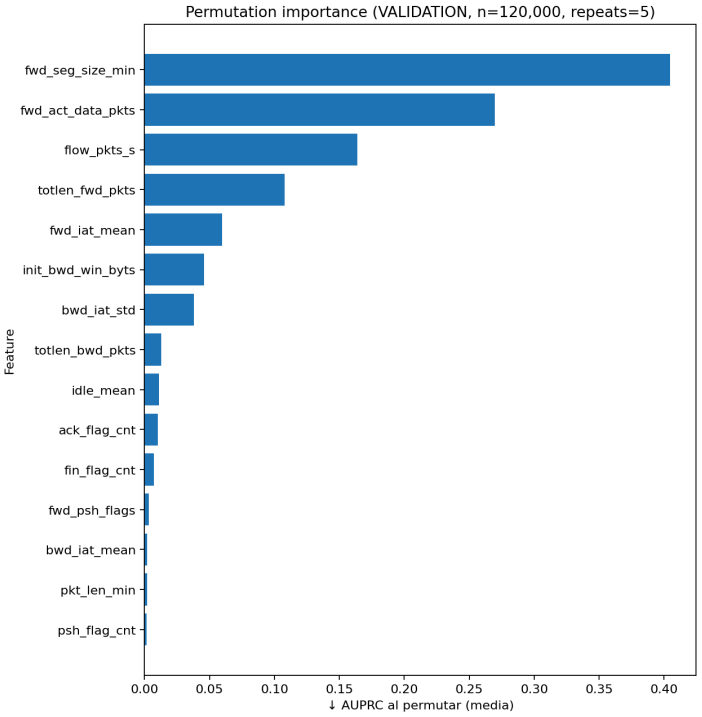

Figura 4.1 : Importància per permutació (VAL)

Lectura breu del rànquing.
El Top-10/15 concentra variables de volum/ritme (`flow_pkts_s`, `totlen_fwd_pkts`), temporalitat (`fwd_iat_mean`, `bwd_iat_std`, `idle_mean`) i transport/flags (`ack_flag_cnt`, `init_bwd_win_byt`). Destaquen `fwd_seg_size_min` i `fwd_act_data_pkts`, coherents amb fluxos curts/intensos o temporalment irregulars. Aquesta anàlisi és interpretativa i no altera el model ni el llindar operatiu.

4.3 Resultats a TEST (mateix τ^*)

Apliquem el mateix τ triat a VAL (NP; §3.7) sense cap reajust. El model mostra separabilitat alta a TEST (corbes ROC/PR consistents), però el punt operatiu evidencia un desplaçament de distribució respecte VAL: amb el mateix llindar, el recall puja fort i la FPR també s'incrementa (sobrepassa el límit $\alpha = 0.005$) . Això és coherent amb la diferència de prevalença i amb canvis en les distribucions $S|Y$ entre conjunts: NP garanteix FPR$\leq\alpha$ a VAL, no a un domini amb *shift*. En entorns reals, això reforça la necessitat de monitoritzar FPR/TPR a τ, aplicar alarma i revisió de τ si la FPR supera el llindar operatiu i, si cal, reentrenar/recalibrar amb dades recents. Malgrat

l'augment de FPR, la precisió es manté alta a TEST pel nivell de prevalença; en escenaris amb prevalença més baixa, s'esperaria una caiguda de la precisió amb el mateix τ (vegeu §3.11).

Conjunt	τ^*	FPR	TPR (Recall)	Precision	F1	AUROC	AUPRC
TEST	0.000045	0.035577	1.000	0.961	0.980	0.96600	0.95088

Taula 4.2: Mètriques a TEST (al mateix τ^* de validació).

4.4 Matriu de confusió a TEST (al llindar τ^*)

La matriu de confusió resumeix la decisió binària al punt operatiu. En aquest TFG s'informa TP, FP, TN i FN, a partir dels quals es deriven Precision, Recall (TPR) i FPR.

- Una FPR propera a α indica que el criteri NP s'ha respectat en dades cegues.
- La diferència entre Recall a VAL i TEST mesura la estabilitat del punt d'operació.

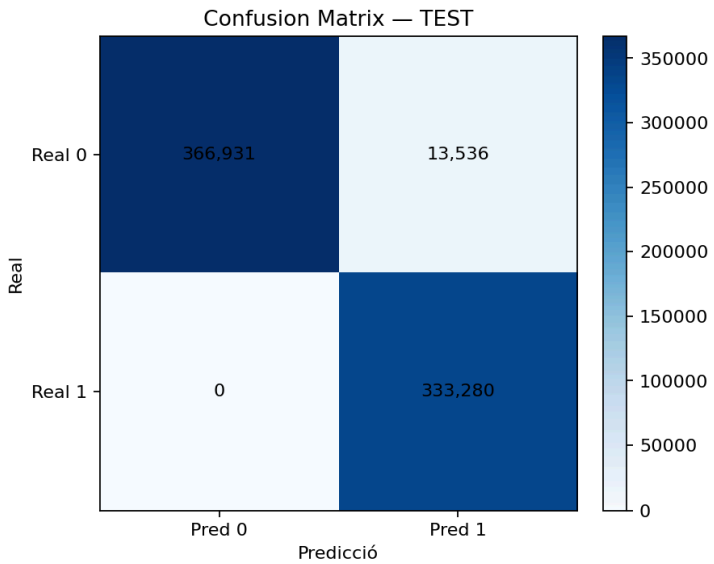

Figura 4.2 : Matriu de confusió a TEST. τ^* triat a VAL i aplicat sense reajust a TEST. Comptes absoluts: TN=366 931, FP=13 536, FN=0, TP=333 280. En aquest punt operatiu: FPR=3.5577%, TPR=1.000, Precision=0.961, F1=0.980 (α objectiu a VAL = 0.5%).

4.5 Corbes ROC i PR (VAL/TEST)

Les corbes ROC i Precision–Recall (PR) permeten comparar l'evolució del compromís TPR–FPR i Precision–Recall al llarg de tots els llindars. En prevalences baixes, la PR és especialment informativa. En els gràfics s'hi marca el punt τ per visualitzar la posició operativa.

En VAL, el punt τ cau prop del límit FPR = α (política NP), mentre que en TEST el mateix τ desplaça la FPR cap amunt, evidenciant shift de distribució. Les àrees (AUROC/AUPRC) resumeixen la capacitat d'ordenació global (independent del llindar) i la PR reflecteix millor l'efecte de la prevalença; per això reportem PR com a figura principal i ROC com a complement.

A continuació observem ambdues corbes:

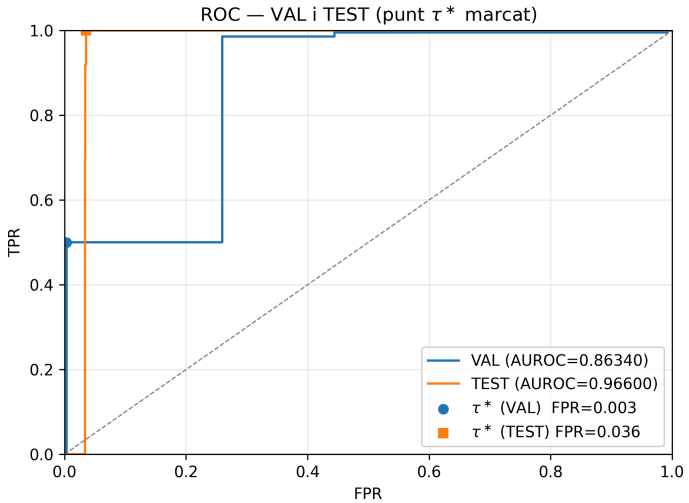

Figura 4.3: Corbes ROC de VAL i TEST. Es marca el punt d'operació corresponent a τ^*.

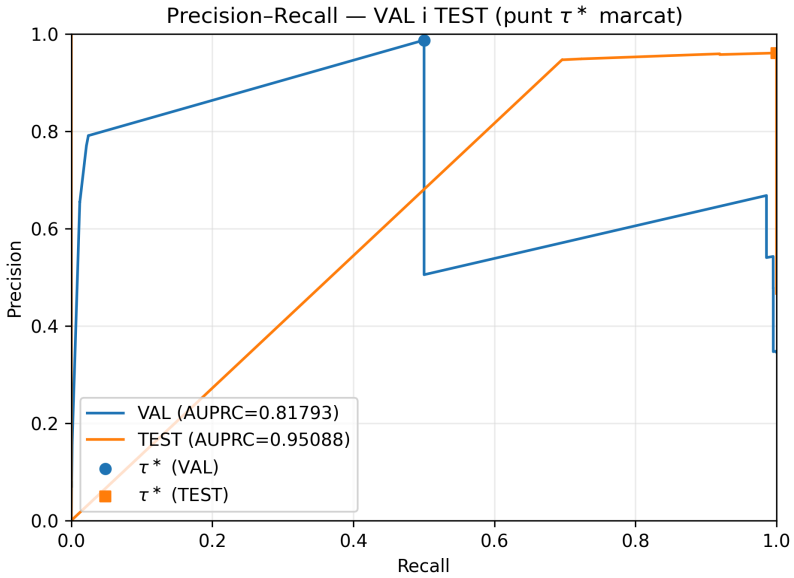

Figura 4.4 : Corbes PR. Es destaca el compromís al τ (punt marcat).

4.6 Cost computacional i recursos

Avaluem el cost en temps i memòria, així com la mida del model i la latència d'inferència. Aquests valors són rellevants per a desplegament en entorns amb recursos limitats:

Mètrica	**Valor**
Temps d'entrenament [min]	0.47
Iteracions utilitzades *(early stopping)*	177
Pic de memòria (Peak RAM) [GiB]	1.0
Mida del model (disc) [MB]	0.7
Latència per flux (inferència) [ms/flux]	0.016
Throughput estimat [flux/s]	62 969
Maquinari (CPU / RAM)	x86_64 /12.7 GB
Sistema / Python	Linux-6.6.105+ /Python 3.12.12
Pandas / NumPy / scikit-learn	2.2.2 / 2.0.2 /1.6.1

Taula 4.3: *Cost computacional (CPU) i recursos. Les xifres de latència i de throughput són orientatives, obtingudes al nostre entorn local amb el pipeline d'inferència estàndard; poden variar segons maquinari i configuració.*

4.7 Discussió

Els resultats mostren que el criteri NP permet controlar el sostre de FPR i, alhora, mantenir un Recall raonable en TEST. La proximitat entre VAL i TEST indica que el particionat per clau evita fuites i que la selecció de *features* és prou robusta per generalitzar. El cost computacional es manté contingut: HGB ofereix una capacitat no lineal competitiva sense dependre de GPU, amb una mida de model moderada i latència adequada a entorns de processament per lots o en línia.

Les diferències entre AUPRC i AUROC s'expliquen per la prevalença: en contextos esparsos, la PR reflecteix millor el rendiment en positius. En aquest marc, informar Recall@FPR=α al mateix τ és la dada que millor representa el compromís operatiu del sistema.

4.8 Resum del capítol

Apliquem el mateix τ triat a VAL (NP; §3.7). Els resultats inclouen AUROC/AUPRC com a mètriques de ranking, i Precision/Recall/F1/Recall@FPR=α com a mètriques de decisió al punt d'operació. La matriu de confusió contextualitza l'impacte d'errors i la secció de cost computacional demostra la viabilitat del model per a desplegament.

CAPÍTOL 5

Anàlisi de sostenibilitat i implicacions ètiques

5.1 Visió general

Aquest TFG presenta un IDS que prioritza la reproduïbilitat i el control del punt d'operació mitjançant Neyman–Pearson. A continuació s'avaluen els seus impactes (operatius, econòmics, socials i ambientals) i es detallen bones pràctiques per a un desplegament responsable, amb especial atenció a la privacitat, els riscos d'ús i la viabilitat energètica.

5.2 Consideracions ètiques i de privacitat

Principi de minimització de dades.

El pipeline evita *features* que siguin identificadors crus (IPs/ports textuals) i es centra en senyals de comportament (taxes, IATs, comptadors). Això redueix el risc de reidentificació i ajuda a complir el principi de minimització (RGPD/GDPR).

Falsos positius i càrrega operativa.

- Amb FPR≤α (α = 0.5%) s'acota la taxa d'alarmes injustificades.
- Tot i així, en volums grans, FP absoluts poden ser rellevants. Cal establir cues de revisió i priorització (per severitat, actius crítics, historial d'incidents).

Falsos negatius i responsabilitat.

- Un FN pot amagar un atac real. El sistema s'ha de veure com a mòdul d'ajuda a decisió, no com a substitut del criteri humà.
- Es recomana una política d'escalat quan hi hagi patrons sospitosos repetits (mateix origen/destí, ports o franges horàries).

Transparència i auditabilitat.

- Export d'artefactes (model, τ, mètriques i manifests) per a auditoria.
- Registre de versions i llavors per traça completa en cas d'incident.

Accés i governança.

- Separació de rols: qui entrena, qui valida, qui opera.
- Logs signats i amb retenció limitada (90 dies) per a traçabilitat i compliment.

5.3 Impacte econòmic (costos i beneficis)

Costos directes.

- ***Cost operatiu:*** la latència (0.016 ms/flux) i el throughput (≈63 k flux/s) permeten cost baix per alerta en CPU estàndard; el cost per FP depèn del temps d'anàlisi (p. ex., 5–15 min).
- **Entrenament**: temps CPU: 0.47 min i consum energètic estimat (vegeu §5.5).
- **Operació**: latència 0.016 ms/flux i *throughput* 62 969 flux/s (Taula 4.3), suficient per a processament per lots i temps real suau (near-real-time, NRT).

Costos induïts pels errors.

- **FP**: temps d'analista $t_{fp} \approx 10$ min ⟶ cost mensual ≈ $\#\#FP_{mes} \cdot t_{fp} \cdot cost_hora$.
- **FN**: risc operacional; cal pla de contenció (segmentació de xarxa, llistes negres temporals, playbooks).

Benefici esperat.

- Reducció de soroll per l'acotació del FPR ⟶ estalvi de temps en NOC/SOC.
- Documentació d'artefactes ⟶ menys temps en post-mortems i auditories.

5.4 Impacte social i legal

Conformitat legal (GDPR/RGPD).

- Es treballa amb agregats i senyals; si calgués correlació amb identitats, que sigui en sistema separat amb pseudonimització i control d'accés.
- Base jurídica: interès legítim de seguretat; imprescindible avaluació d'impacte si el desplegament escala a entorns amb dades personals.

No discriminació i biaixos.

- El model no utilitza atributs protegits; tanmateix, pot heretar biaixos del tràfic històric (p. ex., segments més monitoritzats). Es recomana monitoratge d'equitat bàsic (taxes d'alerta per subnet/segment).

5.5 Sostenibilitat ambiental (energia i petjada de carboni)

5.5.1 Estimació senzilla de consum d'entrenament.

Definim l'energia d'entrenament com:

$$E_{fit} \approx P_{CPU} \cdot U \cdot t \ , t = \frac{0.47\ min}{60} = 0{,}00783 \text{ h.}$$

on P_{CPU} és la potència nominal (W), U la utilització mitjana (0–1) i t el temps d'entrenament (h).

Assumint P_{CPU} = 80W i U = 0,6:

$$E_{fit} \approx 80 \cdot 0{,}6 \cdot 0{,}00783 = 0{,}376 \text{ Wh} = 0{,}000376\text{kWh}$$

Amb un factor d'emissió EF= 0,25 kg$C0_2e/kWh$:

$$CO_2e \approx 0{,}000376 \cdot 0{,}25 = 0{,}000094 \text{ kg } (0{,}094 \text{ g})$$

Estimació d'inferència (per 10^6 fluxos).

Throughput 62 969 flux/s $\Longrightarrow t_{lot} \approx$ 15,9 s = 0,00441 h.

Amb P_{CPU} = 80 W, U = 0,4:

$E_{inf} \approx 80 \cdot 0{,}4 \cdot 0{,}00441 = 0{,}141$ Wh

$CO_2e \approx 0{,}000141 \times 0{,}25 = 0{,}000035$ kg (0,035 g)

Nota: canviant P_CPU, U o EF es pot recalcular fàcilment.

5.5.2 Optimitzacions aplicades i limitacions

Optimitzacions aplicades / recomanades.
— Lectura per fragments i tipus `float32` (menys memòria ⟹ menys *swapping* ⟹ menys energia).
— Early stopping en HGB i mode ràpid en iteracions (reducció de ttt).
— Batching d'inferència i artefactes compactes (I/O menor).
— Preferència per CPU estàndard (sense GPU) per al cas d'ús.

Limitacions.
Són estimacions conservadores; la xifra exacta depèn de maquinari, utilització real i mix elèctric. En operació, es recomana monitoritzar kWh/mes i revisar anualment.

5.6 Riscos i mitigacions

Riscos	Prob.	Impacte	Mitigacions
Fuites de dades (mateix flux/clau en conjunts diferents)	Baixa	Alt	Particionat per clau (70-15-15), unicitat de clau per conjunt, QA amb AUROC sobre etiquetes permutades ≈ 0.5 i revisió de *manifests.*
Excés d'alarmes (FP)	Mitjana	Mitjà/Alt	Neyman-Pearson amb FPR ≤ 0.5% (α=0.005); cues de revisió; rate-limiting d'alertes (ex. ≤ 5 alertes/s per tenant)
Atacs no vistos (FN)	Mitjana	Alt	Playbooks de contenció/escalat; revisió de τ si canvia la prevalença; mostreig actiu d'events amb baixa probabilitat però alt impacte; *threat intel* i tests d'hipòtesi puntuals.
Drift de dades	Mitjana	Mitjà	Monitoratge de distribucions per classe (KS/PSI): alerta si KS > 0.10 o PSI > 0.20; reentrenament condicionat i validació creuada abans de desplegar.
Privacitat i accés indegut	Baixa	Alt	Minimització de dades (només *deploy-safe*), exclusió d'IPs/ports crus, ACLs per artefactes, logging signat i rotació; xifrat en repòs/transit.

Taula 5.1: Riscos i mitigacions. (Prob. = Probabilitat; pp = punts percentuals).

5.7 Bones pràctiques de desplegament i monitoratge

Contracte d'operació.

- Operar sempre amb el mateix τ triat a VAL; si la prevalença canvia (p. ex., període d'incidència), revisar τ amb una finestra recent de validació i documentar el canvi.

Monitoratge continu.

- **Mètriques clau**: volum d'alertes/hora, FPR estimada (sobre mostres etiquetades), Recall aproximat en casos confirmats, i drift de *features*.

- **Llindars d'alarma interna**: Es dispara alerta si hi ha una desviació de ±10 pp en Recall@FPR=α, o si els FP superen 2× la mediana de les darreres 24 h durant ≥30 min, o si la FPR estimada excedeix α + 0.20 pp (amb α = 0.5%).

Manteniment del model.

- No recalibrar (no s'usa calibratge); reentrenar quan es compleixi almenys un d'aquests criteris:

  (i) drift sostingut en les features o en $S \mid Y$(p. ex., durant ≥7 dies)

  (ii) degradació de Recall@FPR=α > 10 pp sostinguda (≥7 dies o en una finestra amb ≥100 casos confirmats).

  (iii) canvi d'entorn (noves aplicacions/ports).

- Control de versions i canary release abans d'activar el nou model.

5.8 Limitacions

- **Dependència del dataset**: tot i la divisió per clau, continuem subjectes a prevalences i tipus d'atac del conjunt CIC-IDS2018.

- **Sense calibratge**: el sistema prioritza NP amb un τ fix; no s'ofereix una probabilitat calibrada "absoluta", tot i que per a l'objectiu d'operació no és necessari.

- **Explicabilitat**: importàncies de *features* donen pista, però no substitueixen anàlisi forense d'un cas.

5.9 Resum del capítol

S'ha descrit com el sistema minimitza riscos ètics i de privacitat, com es controla l'impacte econòmic (especialment el cost dels FP) i com es quantifica i redueix el consum energètic. El contracte operatiu —Neyman–Pearson amb FPR≤α i τ fix— aporta traçabilitat i estabilitat. Amb un monitoratge adequat de drift i mètriques clau, el model és viable per a entorns de producció amb restriccions de recursos i requisits d'auditoria.

CAPÍTOL 6

Conclusions i Línies Futures

6.1 Conclusions principals

Aquest treball ha presentat un IDS (Intrusion Detection System) sobre CIC-IDS2018 dissenyat amb reproduïbilitat i absència de fuites com a condicions de partida. La metodologia —ingesta per fragments, clau de flux i divisió per clau, selecció de features deploy-safe, HGB (Histogram-Based Gradient Boosting) i punt d'operació fixat (NP; §3.7)— ha permès obtenir un sistema auditable, amb artefactes i manifestos que en garanteixen la traçabilitat.

Es manté coherència VAL⟶TEST al τ de NP (§3.7); les diferències entre AUROC/AUPRC (mètriques de ranking) i Recall/Precision/F1 al punt d'operació es mantenen en marges esperables. L'elecció d'HGB ha estat adequada per equilibrar capacitat no lineal i cost CPU, i les features basades en comportament (taxes, IATs, comptadors, flags agregats) han aportat estabilitat sense exposar identificadors sensibles. En síntesi, el TFG lliura: (i) un pipeline replicable sense fuites, (ii) un contracte d'operació clar —(α, τ)— i (iii) un paquet d'artefactes preparat per a revisió i reutilització.

6.2 Acompliment dels objectius

6.2 Acompliment dels objectius

Objectiu general.
S'ha dissenyat, implementat i avaluat un IDS basat en ML (HGB) sobre CIC-IDS2018, amb pipeline reproduïble i eficient. A VALIDACIÓ, el punt operatiu triat amb Neyman–Pearson compleix FPR $\leq \alpha = 0{,}5\%$ (FPR≈0,34%) i es reporta Recall@FPR=α. A TEST, aplicant el mateix τ s'obté FPR≈3,56% (per canvi de distribucions); es discuteix com re-seleccionar τ amb finestra recent en entorns reals (§3.7, §4.3, §5.7).

O.1 Evitar fuites amb clau de flux.
Acomplert. Partició 70–15–15 per clau (5-tupla/flow_id i *fallbacks*), unicitat de clau per conjunt i control de prevalences. QA amb etiquetes permutades (AUROC≈0,5) i manifests de partició (§3.3, §3.9).

O.2 Selecció de característiques per a desplegament.
Acomplert. TOP-25 features deploy-safe, exclusió d'identificadors (IPs/ports/proto/flow_id/flow_key), imputació i min–max après només a TRAIN; traça en `features_meta.json` (§3.4).

O.3 Selecció del llindar τ amb NP.
Acomplert. Càlcul de puntuacions a VAL, corba ROC i τ triat com el mínim que compleix FPR≤α; paràmetres ENV documentats (IDS_MAX_FPR, IDS_MIN_TPR, IDS_NP_MARGIN). Artefactes: decision_thresholds.json, metrics_val.json (§3.6–§3.7).

O.4 Reportar mètriques i cost computacional.
Acomplert. Es reporten AUROC, AUPRC, F1 i Recall@FPR=α en VAL/TEST, i costos: temps d'entrenament ≈ 0,47 min, latència 0,016 ms/flux i throughput 62.969 flux/s; discussió d'eficiència i traça dels experiments (§4.x, §5.3, §5.5).

O.5 Traçabilitat i auditoria.
Acomplert. Emmagatzematge de model, τ, mètriques, manifests de partició/features/versions i ZIP d'export amb instruccions d'inferència (§3.8, §3.10).

Conclusió.
Els objectius es compleixen en VALIDACIÓ (contracte FPR≤0,5%); A TEST, aplicant el mateix τ triat a VAL, no es compleix el límit (FPR≈3,56%), indicant canvi de distribucions; en un entorn real es re-seleccionaria τ amb finestra recent per restablir FPR≤α (vegeu §3.7 i §5.7).

6.3 Limitacions

- **Dependència del dataset.** Encara que la divisió per clau evita fuites, els resultats reflecteixen la prevalença i els tipus d'atac propis de CIC-IDS2018.
- **Punt d'operació únic.** Operar amb un τ fix és simple i auditable, però pot requerir reajust si canvia la prevalença o el perfil de tràfic.
- **Explicabilitat limitada.** Les importàncies de *features* orienten, però no substitueixen l'anàlisi d'incidents.

6.4 Línies futures

1. **Adaptació del llindar al context (cost-sensitive).** Estendre el criteri NP per incorporar costs de FP/FN i prevalença estimada en producció, definint τ de manera dinàmica però auditada (finestres temporals i *change logs*).

2. **Detecció de *drift*.** Monitorar distribucions de *features* (p. ex., KS/PSI) i mètriques clau (Recall@FPR=α).

3. **Ampliació de *features* segures.** Afegir buckets de ports, codificacions one-hot de proto a nivell gros o descriptors temporals (franges horàries) que no revelin identitat però millorin cobertura.

4. **Portabilitat entre jocs de dades i xarxes.** Replicar el pipeline a UNSW-NB15 i a captures pròpies; estudiar canvis de τ i de Recall@FPR=α.

5. **Integració operativa.** Publicar API/CLI d'inferència amb `hgb_model.pkl`, llista de *features* i τ; afegir logs signats i dashboards mínims (alarmes/hora, FP estimats, drift).

6. **Avaluacions d'estrès.** Tests amb prevalences extremes i escenaris d'atac no vistos per quantificar la zona de fallada i establir playbooks de resposta.

7. **Implementació híbrida (signatures + ML).** Integrar un motor de signatures (p. ex., Snort/Suricata) per a amenaces conegudes (baix FP) amb el model ML per a detecció d'anomalies amb NP (FPR$\leq\alpha$). Disseny en cascada: (i) tràfic que matxa una regla d'alta severitat $\Rightarrow$ alerta directa; (ii) tràfic no cobert $\Rightarrow$ passa al classificador HGB; (iii) correlació i deduplicació d'alertes. Objectiu: reduir soroll i millorar cobertura mantenint traçabilitat (change logs) i mètriques separades per via signature i via ML.

6.5 Cloenda

El treball aconsegueix l'objectiu que es va fixar: un IDS simple d'operar, reproduïble i sense fuites, amb punt d'operació explicitat i mètriques consistents entre validació i test. La contribució principal no és només un valor concret d'AUROC o AUPRC, sinó un procediment que qualsevol equip pot auditar, repetir i adaptar. Amb les línies futures proposades —ajust de τ segons context, monitoratge de drift i portabilitat— el sistema pot evolucionar cap a un desplegament fiable en entorns reals.

Bibliografia

[1] P. García-Teodoro *et al.* «Anomaly-based network intrusion detection: techniques, systems and challenges». *Computers & Security*, 28(1–2), 2009, pàgs. 18-28. doi: 10.1016/j.cose.2008.08.003

[2] R. Sommer, V. Paxson. «Outside the Closed World: On Using Machine Learning for Network Intrusion Detection». En: *IEEE Symposium on Security and Privacy*. 2010, pàgs. 305-316. doi: 10.1109/SP.2010.25.

[3] Canadian Institute for Cybersecurity. *Intrusion Detection Evaluation Datasets CIC-IDS2017 & CSE-CIC-IDS2018*. 2017. url: https://www.unb.ca/cic/datasets/

[4] N. Moustafa, J. Slay. «UNSW-NB15: a comprehensive data set for network intrusion detection systems». En: *Military Communications and Information Systems Conference (MilCIS)*. 2015, pàgs. 1-6. doi: 10.1109/MilCIS.2015.7348942

[5] P. Goldschmidt, D. Chudá. «Network Intrusion Datasets: a survey, limitations, and recommendations». *Preprint*, 2025. url: https://arxiv.org/abs/2502.06688

[6] Y. Mirsky, T. Doitshman, Y. Elovici, A. Shabtai. «Kitsune: An Ensemble of Autoencoders for Online Network Intrusion Detection». En: Network and Distributed System Security Symposium (NDSS). 2018. doi: 10.14722/NDSS.2018.23204

[7] Vectra AI. *Sustituya su sistema de detección de intrusiones (IDS)*. 2024. url: https://es.vectra.ai/solutions/use-cases/ids-replacement

[8] A. L. Buczak, E. Guven. «A Survey of Data Mining and Machine Learning for Cybersecurity Intrusion Detection». *IEEE Communications Surveys & Tutorials*, 18(2), 2016, pàgs. 1153-1176. doi: 10.1109/COMST.2015.2494502

[9] T. Chen, C. Guestrin. «XGBoost: A Scalable Tree Boosting System». En: *Proc. of the 22nd ACM SIGKDD Int. Conf. on Knowledge Discovery and Data Mining (KDD)*. 2016, pàgs. 785-794. doi: 10.1145/2939672.2939785

[10] Y. Zhang, R. C. Muniyandi, F. Qamar. "A Review of Deep Learning Applications in Intrusion Detection Systems: Overcoming Challenges in Spatiotemporal Feature Extraction and Data Imbalance." *Applied Sciences*, 15(3), 1552, 2025. doi: 10.3390/app15031552

[11] Scikit-learn Developers. *HistGradientBoostingClassifier — scikit-learn documentation*. 2023. url:https://scikit-learn.org/stable/modules/ensemble.html#histgradientboostingclassifier

[12] M. V. Mahoney, P. K. Chan. «An analysis of the 1999 DARPA/Lincoln Laboratory evaluation data for network anomaly detection». En: *Recent Advances in Intrusion Detection (RAID 2003)*. LNCS 2820, 2003, pàgs. 220–237. doi: 10.1007/978-3-540-45248-5_13.

[13] Scikit-learn Developers. *Cross-validation: evaluating estimator performance*. 2024. url: https://scikit-learn.org/stable/modules/cross_validation.html

[14] J. McHugh. «Testing intrusion detection systems: a critique of the 1998 DARPA intrusion detection system evaluations as performed by Lincoln Laboratory». *ACM TISSEC*, 3(4), 2000, pàgs. 262-294. doi: 10.1145/382912.382923.

[15] DVC. *Data Version Control Documentation*. 2025. url: https://dvc.org/doc

APÈNDIX A

Altres definicions

A.1 Drift

Sigui X és el vector de features d'un flux i $P(X)$ la seva distribució:

Anomenem drift qualsevol canvi sostingut en $P(X)$, $P(Y)$ o $P(Y|\ X)$ entre períodes d'operació. Quan es desplaça $S \mid Y = 0$ pot pujar la FPR al mateix τ; si es desplaça $S \mid Y = 1$ pot baixar el recall; un canvi només de $P(Y)$ manté ROC/FPR/TPR però empitjora precision/F1.

A.2 Peeking

Peeking és utilitzar informació de VALIDACIÓ o TEST per prendre decisions del model (entrenament, selecció de features, hiperparàmetres o llindar τ). És "mirar i ajustar" segons el rendiment i això infla les mètriques.

Política d'aquest TFG: tot s'aprèn amb TRAIN; τ es fixa només a VAL i s'aplica igual a TEST, sense cap reajust després de veure TEST.

A.3. Distribucions de puntuacions condicionades

Sigui S la puntuació del model i $Y \in \{0, 1\}$ la classe (0=benigne, 1=atac). Escriurem $S \mid Y = 0$ i $S \mid Y = 1$ per referir-nos a les distribucions de puntuacions condicionades a cada classe. Aquesta notació s'utilitza per explicar l'efecte de canvis de distribució entre VAL i TEST.